

Uma aplicação de análise de sentimentos para predição da inflação brasileira

Acadêmico: Lucas Miranda Mendonça Rezende

Orientador: Evandro Eduardo Seron Ruiz*

Departamento de Computação e Matemática – FFCLRP, USP

5 de junho de 2025

Palavas-chave: análise de sentimentos, inflação, inteligência artificial.

Resumo

O controle da inflação é uma tarefa essencial para garantir a estabilidade econômica de um país. Bancos centrais implementam políticas monetárias e fiscais para controlar a inflação e, conseqüentemente, preservar o poder de compra da moeda. Concomitantemente, percebemos que os eventuais ajustes necessários para o controle da inflação, tais como mecanismos de alteração da taxa de juros, provocam inquietações no ambiente econômico que refletem diretamente no cotidiano das famílias, provocando assim reações e especulações na mídia. Este trabalho busca identificar os sentimentos expressos diante dos reflexos da divulgação de índices de inflação e analisa se os esses mesmos sentimentos podem impactar os modelos de previsão de inflação. Por consequência, também avaliaremos se métodos de análise de sentimentos podem trazer um viés na sua avaliação relativamente à perspectiva humana.

1 Introdução

O controle da inflação tem sido um dos principais desafios enfrentados pelos responsáveis pela elaboração de políticas econômicas em nível global (WANG et al., 2022). Inflação é o nome dado ao aumento dos preços de produtos e serviços. Economias que lidam com altas taxas de inflação

*ORCID: 0000-0002-7434-897X.

frequentemente enfrentam dificuldades no processo de crescimento, pois medidas econômicas de curto prazo, como a política monetária, precisam ser direcionadas principalmente para combatê-la. Desde a história do pensamento econômico, o controle da inflação tem sido um tema de grande relevância, dada sua importância social. Neste contexto, merecem destaque também os métodos de predição de inflação (NARAYANAA et al., 2023).

A análise de sentimentos é uma área do Processamento de Língua Natural (PLN) que busca identificar e extrair informações subjetivas de textos, determinando a polaridade emocional, como positiva, negativa ou neutra (WANKHADE; RAO; KULKARNI, 2022). Utilizando técnicas de processamento de linguagem natural (PLN), podemos compreender amplamente as opiniões e emoções expressas em grandes volumes de dados textuais; inclusive, podemos usar para avaliar o impacto de políticas públicas na sociedade (ALMANSA et al., 2014), incluindo as políticas de controle inflacionário (SIMIONESCU, 2025).

Hipóteses de trabalho Consideramos que as eventuais opiniões sobre o controle da inflação possam, de alguma maneira, afetar a previsão de inflação do mês subsequente. Como iremos utilizar métodos automatizados de análise de sentimentos em textos econômicos, aproveitaremos estes métodos para avaliar se os mesmos apresentam algum viés de avaliação relativamente às avaliações humanas.

1.1 Objetivo

Este trabalho tem dois objetivos de destaque, que são:

1. O primeiro objetivo deste trabalho é analisar os sentimentos expressos sobre a evolução da inflação entre os períodos de divulgação dos dados de inflação no Brasil. Os resultados destas análises servirão, como variável exógena, para alimentar modelos de previsão inflacionária que estão sendo estudados e desenvolvidos por um economista, mestrando, no mesmo laboratório de estudo;
2. O segundo objetivo é avaliar se métodos de análise de sentimentos podem ou não apresentar viés de avaliação relativamente às avaliações humanas.

Reforço que esta **proposta de trabalho está vinculada a um projeto de pesquisa de um pós-graduando** que está pesquisando sobre modelos computacionais de previsão de inflação, tanto os modelos canônicos (modelos estatísticos), como os modelos baseados em Inteligência Artificial.

2 Metodologia

A análise de sentimentos aplicada a textos que discutem dados sobre a inflação pode ser uma ferramenta poderosa para entender o tom e as perspectivas subjacentes às previsões econômicas. Neste projeto, adotaremos dois modelos de análise de sentimentos:

Léxico A abordagem léxica de análise de sentimentos é tal que utiliza um conjunto de palavras, também chamado de léxico, *gazetteer*, ou dicionário, cujos termos são associadas à uma polaridade emocional: são positivas (+1), negativas (-1) ou neutras (0). Durante o processo de análise, o texto é rotulado de acordo com as valências atribuídas às palavras no léxico de referência (TABOADA et al., 2011); e

LLM A utilização de *Large Language Models* (LLMs), como GPT (chatGPT), Gemini, Claude e seus semelhantes, para analisar sentimentos representa um avanço significativo na área de PLN. Esses modelos, treinados com vastas quantidades de textos em diversos idiomas e contextos, possuem uma compreensão profunda das nuances linguísticas, incluindo emoções, sarcasmo, ironia e contextos culturais. Ao aplicar LLMs na análise de sentimentos, é possível obter resultados precisos e contextualmente sensíveis, avaliando combinações complexas de palavras e frases que podem indicar emoções positivas, negativas ou neutras (SUN et al., 2023).

Embora o modelo léxico seja suscetível ao contexto das palavras e à ordem que aparecem no texto, usaremos este modelo como um *baseline*, ou seja, um patamar mínimo de avaliação.

2.1 Dados

Os dados mensais sobre a inflação são publicados pelo IBGE, como os dados do IPCA, e estão disponíveis no site¹. O IBGE disponibiliza dados de todos os anos a partir de 1995. Recordo que o IPCA, Índice Nacional de Preços ao Consumidor Amplo, é considerado o índice oficial pelo governo federal.

Trimestralmente o Banco Central do Brasil, BCB, publica o Relatório de Política Monetária (RPM)² que apresenta as diretrizes das políticas adotadas pelo Copom, Comitê de Política Monetária, que, dentre outros dados, indica as projeções de inflação. Segundo Pita e Bessaria (JESUS; BESARRIA, 2022)

A ata do Copom é um dos principais instrumentos de comunicação do Banco Central do Brasil, apresenta projeções econô-

¹<https://www.ibge.gov.br/estatisticas/economicas/precos-e-custos/9256-indice-nacional-de-precos-ao-consumidor-amplo.html>

²<https://www.bcb.gov.br/publicacoes/rpm>

micas para o cenário nacional e internacional, controle da inflação, decisões a respeito dos juros, etc. É através dela que a autoridade monetária explica os procedimentos utilizados para a tomada de decisão de política monetária com o objetivo de tornar a comunicação mais transparente e manter sob controle as expectativas.

Será a partir destas atas das reuniões do Compom que deveremos analisar os sentimentos sobre a inflação e usar os resultados desta análise para inserir nos algoritmos de previsão.

Estes dados textuais precisam ser tratados, pré-processados, antes de serem ‘traduzidos’ como um índice numérico que revele a positividade (+1) ou negatividade (-1) sobre os sentimentos em relação à inflação. Para tanto, precisaremos de léxicos, relações de palavras e valências dos sentimentos.

Na língua portuguesa a possibilidade de usar três listas diferentes, que são:

LIWC O dicionário Brazilian Portuguese LIWC é um léxico que foi desenvolvido a partir do dicionário original de LIWC em inglês (PENNEBAKER; FRANCIS; BOOTH, 2001). O objetivo deste léxico é agrupar palavras em categorias que possam ser usadas para analisar características psicolinguísticas em textos. O dicionário LIWC possui 127.149 entradas, onde cada entrada pode ser atribuída a uma ou mais categorias. As duas categorias utilizadas nesta avaliação são *posemo* (12.878 entradas), que representa emoções positivas, e *negemo* (15.115 entradas), que representa emoções negativas;

OpinionLexicon O OpinionLexicon (SOUZA; VIEIRA, 2011) é um dicionário específico para a tarefa de análise de sentimentos. Para construir esse recurso, os autores aplicaram três métodos da literatura: baseado em corpus, baseado em tesauro e um sistema de tradução automática. O léxico na versão 2.1 é composto por 30.678 entradas (30.236 palavras e 442 frases); e

SentiLex O SentiLex (CARVALHO; SILVA, 2015) é um léxico desenvolvido para o domínio dos julgamentos sociais. A abordagem do léxico foi construída a partir de recursos linguísticos disponíveis publicamente e ampliada por uma combinação de estratégias baseadas em linguística e aprendizado de máquina. O SentiLex (versão 2) é composto por 82.347 formas flexionadas.

Avaliação humana Para avaliar o eventual viés dos métodos em relação às opiniões dos seres humanos, faremos um questionário com um número n de frases sobre a inflação, sendo as mesmas que serão avaliadas pelos modelos capturadas das fontes citadas na seção *Dados*, e pediremos aos estudantes do curso de Economia do nosso campus para avaliar a valência (positiva,

negativa ou neutra) de cada frase. O número n ainda não está definido, tampouco o número de indivíduos, pois ainda estamos avaliando com um docente da área de Estatística os números necessários para um resultado aceitável e viável.

2.2 Pré-processamento de Dados

Os dados textuais dos relatórios passam inicialmente por um rigoroso processo de pré-processamento para garantir que estejam prontos para a análise. Este processo inclui:

Tokenização Quebra do texto em unidades menores, como palavras ou frases.

Remoção de Stopwords Eliminação de palavras comuns que não carregam significado próprio, como preposições e artigos.

Stemming Redução das palavras às suas formas básicas para uniformizar o texto.

2.3 Análise de sentimentos

Como mencionado anteriormente, aplicaremos dois modelos de análise de sentimentos, o modelo léxico e o modelo baseado em grandes modelos de linguagem.

2.3.1 Modelo léxico

Para aplicar o modelo léxico na avaliação de frases de um conjunto de documentos, o primeiro passo é selecionar um dicionário de sentimentos adequado, que contenha palavras associadas às categorias de sentimentos positivas, negativas ou neutras. Em seguida, realiza-se o pré-processamento das frases, incluindo etapas como tokenização (dividir o texto em palavras ou unidades menores), remoção de stopwords (palavras de pouco significado) e o *stemming*.

Depois, o algoritmo percorre cada frase, identificando as palavras presentes no léxico. Para cada palavra encontrada, registra-se sua associação de sentimento (positivo, negativo ou neutro) e, geralmente, atribui-se um peso ou pontuação. A soma dessas pontuações em uma frase fornece uma medida global do sentimento daquela frase. Se a soma for positiva, a frase é classificada como positiva; se for negativa, como negativa; e, se estiver próxima do zero ou apresentar um equilíbrio, como neutra.

Por fim, essas classificações podem ser agregadas para avaliar o sentimento geral de um documento inteiro ou de um conjunto de textos, facilitando análises quantitativas do sentimento predominante. Essa abordagem

é simples, eficiente e útil para análises rápidas, embora possa ser complementada com técnicas mais avançadas para maior precisão.

2.3.2 LLM

Para aplicar a API de Large Language Models (LLMs) na avaliação de frases de um conjunto de documentos como positivas, negativas ou neutras, o procedimento envolve o uso de prompts (instruções) bem estruturados para que o modelo interprete e classifique o sentimento de cada frase. A seguir, um passo a passo para essa aplicação:

- Faça o pré-processamento inicial das frases, garantindo que estejam limpas e bem delimitadas, para facilitar a entrada na API;
- Crie um *prompt*, uma chamada instrutiva, clara e objetiva, instruindo o modelo a classificar cada frase de acordo com o sentimento, ou seja, positiva, neutra ou negativa;
- Envie cada frase ou um conjunto de frases ao modelo usando a API, incluindo o *prompt*, e capte as respostas retornadas pelo LLM, que devem indicar a classificação;
- Extraia a classificação de cada resposta, que geralmente será uma palavra ou frase como “positiva”, “negativa” ou “neutra”.
- Após obter as classificações para todas as frases, deveremos agregá-las para entender o sentimento predominante nos documentos ou realizar análises estatísticas.

Como teremos um conjunto grande de documentos, implementaremos scripts que percorram automaticamente as frases, gerando os prompts, chamando a API e armazenando as classificações para análise posterior.

Esse método, usando a API de LLMs, aproveita a capacidade do modelo de entender contextos complexos e nuances de linguagem, proporcionando uma classificação mais precisa do sentimento em comparação com abordagens baseadas apenas em léxicos.

2.4 Avaliação

Para avaliarmos ambos os métodos, devemos reunir um conjunto de frases a analisá-las manualmente. Este será o conjunto de n frases avaliadas por m avaliadores.

Para gerar uma frase ‘consenso’ entre os m avaliadores, poderemos usar o sistema de votação em que as frases mais votadas para uma valência específica, seja ela positiva, negativa ou neutra, recebem este rótulo.

As métricas de avaliação incluem precisão, revocação e F1-score, e permitem avaliar o desempenho de ambos modelos, léxico e LLM, na classificação de sentimentos em textos econômicos.

Para melhor representação das métricas utilizadas neste trabalho, será criada a matriz de confusão representada na Tabela 1. As colunas representam classificações realizadas por humanos. Para a classe ‘Positivo’, são separadas as instâncias corretamente classificadas pelo método com (VP – Verdadeiro Positivo), para a classe ‘Negativo’ (FNP – Falso Negativo Positivo) e como Neutro (FnP – Falso Neutro Positivo). Equivalentemente para as demais colunas teremos, classe ‘Negativo’ (FPN – Falso Positivo Negativo), (VN – Verdadeiro Negativo) e (FnN – Falso Neutro Negativo), como também ‘Neutro’ (FPn – Falso Positivo Neutro), (FNn – Falso Negativo Neutro) e (Vn – Verdadeiro Neutro).

| | Humano | | | |
|-----|----------|----------|----------|--------|
| | Positivo | Negativo | Neutro | |
| VP | FPN | FPn | Positivo | Método |
| FNP | VN | FNn | Negativo | |
| FnP | FnN | Vn | Neutro | |

Tabela 1: Matriz de confusão para os rótulos das frases.

Definida a matriz de confusão e definindo uma quantidade de frases que iremos rotular manualmente, podemos calcular precisão (P), Equação 1, revocação (R) Equação 2 e F1-score, Equação 3, usando as formulações a seguir:

$$P = \frac{VP}{VP + FPN + FPn} \quad (1)$$

$$R = \frac{VP}{VP + FNP + FnP} \quad (2)$$

$$F1 - score = \frac{2 \times P \times R}{P + R} \quad (3)$$

Avaliação do viés Para a avaliação de um eventual viés analítico dos métodos, usaremos uma metodologia que considera o valor discreto total das frases de um documento e que calcula um valor real no domínio $[-1, +1]$ para cada frase através da média ponderada dos valores discretos atribuídos a cada frase. A eventual diferença entre os valores no universo contínuo das frases avaliadas pelos modelos computacionais e as frases avaliadas por humanos evidenciará a existência ou não de um viés.

3 Cronograma

Podemos resumir o trabalho proposto em quatro grandes tarefas, que são:

1. Leitura e estudo da literatura sobre o tema de Análise de Sentimentos (AS) e também sobre aplicações de AS na previsão de inflação;
2. Realizar a recuperação dos Relatórios de Política Monetária (RPM), organizar os arquivos num repositório e fazer os primeiros testes com as tarefas de pré-processamento;
3. Desenvolvimento, teste e análise dos processos de Análise de Sentimentos (AS) nas frases específicas sobre inflação; e
4. Avaliar os dados advindos da AS nos modelos de previsão de inflação, testes e escrita de um artigo acadêmico para uma conferência sobre Processamento de Língua Natural.

| | Atividade | | | |
|------------|------------------|---|---|---|
| Mês | 1 | 2 | 3 | 4 |
| Agosto | ★ | ★ | | |
| Setembro | ★ | ★ | | |
| Outubro | | ★ | ★ | |
| Novembro | | | ★ | ★ |
| Dezembro | | | | ★ |

Tabela 2: Cronograma de execução do plano de trabalho.

Referências

- ALMANSA, L. F. et al. Information learned from monitoring microblogs during the 2014 seasonal flu vaccination in Brazil. In: IEEE. *2014 IEEE 10th International Conference on e-Science*. [S.l.], 2014. v. 2, p. 65–66.
- CARVALHO, P.; SILVA, M. J. SentiLex-PT: Principais características e potencialidades. *Oslo Studies in Language*, v. 7, n. 1, 2015.
- JESUS, D. P. de; BESARRIA, C. N. da. *Narrativas do Banco Central e Previsões Macroeconômicas: Usando Análise Textual de Machine Learning*. [S.l.]: ANPEC, 2022.
- NARAYANAA, T. L. et al. Inflation Prediction: A Comparative Study of ARIMA and LSTM Models Across Different Temporal Resolutions. In: IEEE. *2023 3rd International Conference on Innovative Mechanisms for Industry Applications (ICIMIA)*. [S.l.], 2023. p. 1390–1395.
- PENNEBAKER, J. W.; FRANCIS, M. E.; BOOTH, R. J. Linguistic Inquiry and Word Count: LIWC 2001. *Mahway: Lawrence Erlbaum Associates*, v. 71, 2001.
- SIMIONESCU, M. Machine Learning vs. Econometric Models to Forecast Inflation Rate in Romania? The Role of Sentiment Analysis. *Mathematics*, MDPI, v. 13, n. 1, p. 168, 2025.
- SOUZA, M.; VIEIRA, R. Construction of a portuguese opinion lexicon from multiple resources. *Anais do Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana, 2011, Brasil.*, 2011.
- SUN, X. et al. Sentiment analysis through LLM negotiations. *arXiv preprint arXiv:2311.01876*, 2023.
- TABOADA, M. et al. Lexicon-based methods for sentiment analysis. *Computational linguistics*, MIT Press One Rogers Street, Cambridge, MA 02142-1209, USA journals-info . . . , v. 37, n. 2, p. 267–307, 2011.
- WANG, X. et al. A review of inflation from 1906 to 2022: a comprehensive analysis of inflation studies from a global perspective. *Oeconomia Copernicana*, Instytut Badań Gospodarczych, v. 13, n. 3, p. 595–631, 2022.
- WANKHADE, M.; RAO, A. C. S.; KULKARNI, C. A survey on sentiment analysis methods, applications, and challenges. *Artificial Intelligence Review*, Springer, v. 55, n. 7, p. 5731–5780, 2022.